

Lectura y resumen de tres artículos

Cada resumen responde: (1) problema, (2) datos, (3) modelado, (4) preguntas que responde el sistema y (5) limitaciones y trabajo futuro.

El artículo 1 corresponde a nuestro proyecto asignado y se leyó con mayor profundidad.

Artículo 1. Datos sísmicos (proyecto asignado)

Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. *AZCATL Revista de Divulgación en Ciencias, Ingeniería e Innovación*, 4(6), 28-33. <https://doi.org/10.24275/AZC2026E1004>

1. Problema. México está sobre el Cinturón de Fuego del Pacífico y cinco placas tectónicas interactúan en su territorio; los autores señalan que cerca del 70 % del país tiene riesgo sísmico, incluidas zonas muy pobladas como el Valle de México y Guadalajara. Como los sismos no pueden pronosticarse con certeza, contar con datos confiables de magnitud, profundidad y ubicación es lo que permite estudiarlos. El Servicio Sismológico Nacional (SSN) publica esos datos, pero en un formato técnico y poco amigable. El trabajo busca que cualquier persona —autoridades, docentes, investigadores— pueda explorarlos sin manipular los archivos directamente.

2. Datos. Se descarga del SSN un CSV con más de 300 000 sismos desde 1900 y del INEGI dos CSV: el Censo de Población y Vivienda 2020 y los Censos Económicos (el texto dice 2019, aunque la bibliografía cita la edición 2024). Un programa en Python revisa los archivos, descarta registros con campos vacíos, coordenadas inconsistentes o formatos incompatibles, y genera código SQL que se carga en PostgreSQL. Al revisar el repositorio confirmamos que se distribuyen los SQL ya generados, pero no el programa de validación.

3. Modelado. El artículo, por ser de divulgación, solo dice que la información se organiza como almacén de datos. En el repositorio el modelo es un esquema en estrella: dimensiones de sismos (magnitud, coordenadas, profundidad, referencia y estado), tiempo, zonas (población por entidad) y economía (producción bruta, valor agregado, formación de capital, etc.), y una tabla de hechos que relaciona cada sismo con su entidad y guarda población afectada, impacto económico e indicadores de riesgo. El vínculo entre lo sísmico y lo socioeconómico es la entidad federativa.

4. Preguntas que responde. ¿Qué sismos de cierta magnitud ocurrieron en un periodo y dónde? ¿Cómo se distribuyen por rangos de magnitud y de profundidad? ¿Cuál fue la actividad de un estado en un año (el ejemplo es Jalisco en 2017)? ¿Qué zonas pobladas están cerca de los epicentros? Además ofrece mapas de calor y reportes a la medida que combinan filtros de fecha, magnitud, localidad, profundidad, población y producción económica. Los autores proponen usos en planeación territorial y rutas de evacuación, en educación para la prevención y en investigación sobre la evolución de la actividad en 125 años de registros.

5. Limitaciones y trabajo futuro. Reconocen que no es posible predecir sismos y que instalar el sistema puede ser difícil para usuarios sin experiencia, lo que resolvieron empaquetándolo con Docker Compose en dos contenedores (base de datos y servidor web PHP). Como trabajo futuro plantean visualizaciones 3D, más fuentes oficiales e integración con plataformas de alerta temprana. Como observación propia, al poner en marcha el sistema encontramos que el 38.5 % de los sismos no llega a la tabla de hechos porque no tiene estado asignado, incluido el sismo de magnitud 8.2 de septiembre de 2017; el artículo no menciona esta pérdida.

Artículo 2. Consumo de agua en la Ciudad de México

Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A., y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications*

and Research. Springer.

1. Problema. La Ciudad de México vive una crisis hídrica por sobreexplotación del acuífero, fugas y crecimiento poblacional. SACMEX publica datos abiertos de consumo, pero en archivos poco accesibles y sin herramientas de consulta, de modo que casi no se usan para decidir. El trabajo construye un almacén que consolida esos datos y una interfaz para recuperarlos por territorio, pensada para ciudadanos, servidores públicos, investigadores y periodistas.

2. Datos. La fuente es el recurso *Consumo Agua (1er Semestre 2019)* del portal de datos abiertos: 71 102 registros de los tres primeros bimestres de 2019, publicado una sola vez y sin versiones. El ETL lee los CSV, valida y limpia, carga a tablas de paso con COPY, puebla dimensiones y llena los hechos mediante uniones internas. Solo se descartaron 216 registros (0.3 %), todos con la etiqueta territorial “NA”, y quedaron 70 886. Se integró además una serie climática diaria de Open-Meteo y la cartografía de OpenStreetMap.

3. Modelado. Esquema en estrella con dos hechos, *fact_consumo_agua* y *fact_clima*, y tres dimensiones conformadas: tiempo (181 días), ubicación (1 553 pares alcaldía-colonia con coordenadas) e índice de desarrollo (cuatro niveles). La granularidad es una manzana por periodo de facturación. Con un mapeo R2RML el almacén se repubblica como grafo RDF Data Cube ($\approx 7.6 \times 10^5$ triplets) validado contra las restricciones del vocabulario, con una relación propia de cercanía entre colonias a menos de 1.5 km.

4. Preguntas que responde. Consumo por alcaldía, colonia, bimestre o nivel de desarrollo; cuáles son las alcaldías que más consumen (Cuauhtémoc y Miguel Hidalgo); qué colonias vecinas de una zona seleccionada consumen más, mediante un recorrido del grafo; y qué colonias se desvían más de su alcaldía, mediante una puntuación z que, en pruebas con anomalías inyectadas, ordena casi tan bien como Isolation Forest (ROC-AUC 0.966 contra 0.971). También distingue consumo doméstico de no doméstico.

5. Limitaciones y trabajo futuro. Solo hay tres bimestres de un año, así que no se puede hablar de estacionalidad ni de causas climáticas; la evaluación de anomalías usa perturbaciones sintéticas y es una cota superior; las colonias son centroides y no polígonos; y la relación entre desarrollo y consumo es solo descriptiva. Proponen un triple store con endpoint SPARQL público, usar polígonos oficiales, alinear identificadores con autoridades externas, reevaluar las anomalías con fugas etiquetadas y llevar el método a movilidad, calidad del aire y riesgo sísmico.

Artículo 3. Obra pública municipal

González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En *Advances in Computer Science Applications and Research*. Springer.

1. Problema. Las direcciones de obras públicas de los municipios manejan contratistas, presupuestos, supervisión, fotografías y actas con hojas de cálculo o sistemas aislados, lo que impide analizar la historia de una obra, detectar retrasos a tiempo y abrir la información a la ciudadanía. El caso es Temascaltepec, Estado de México (64 844 habitantes en 55 comunidades). Los autores proponen un almacén dimensional sobre servicios de uso general (PostgreSQL/Supabase y almacenamiento de objetos tipo S3), sin el costo de una plataforma empresarial, y aclaran que no es un *lakehouse* completo.

2. Datos. Todos los datos son sintéticos, porque la privacidad impide publicar registros reales: un generador con semilla crea 1 247 obras, 127.4 millones de pesos de presupuesto, 8 934 eventos de auditoría y 29 928 filas mensuales; solo las coordenadas de las comunidades son reales (OpenStreetMap). En operación, los datos entrarían por formularios web; en lugar de un ETL externo, triggers de la base copian los cambios al almacén, y las fotos y PDF se guardan en Cloudflare R2 con rutas particionadas por obra y mes.

3. Modelado. Esquema en estrella con diez dimensiones —cinco de cambio lento tipo 2 (obra, región, empresa, personal y presupuesto), tres tipo 1 y dos tipo 0— y dos tablas de hechos: eventos de auditoría (un evento atómico por fila, 17 tipos, particionada por año) e instantánea mensual por obra. Encima hay seis vistas no materializadas para retrasos, alertas, trazabilidad, participación, presupuesto ejercido y anomalías. Los autores explican por qué cada entidad recibe su tipo de SCD.

4. Preguntas que responde. ¿Qué monto estaba vigente cuando se autorizó un pago? ¿A qué contratista se atribuye el avance antes de una reasignación? ¿Qué obras van retrasadas y cuántos días? ¿Cuánto se ha ejercido por fuente de financiamiento? ¿Cómo participa la ciudadanía por región? ¿Qué obras presentan costo atípico, retraso extremo o avance financiero muy superior al físico (criterios C1-C3)?

5. Limitaciones y trabajo futuro. No hay despliegue dinámico en línea; la votación ciudadana es simple; la calidad depende de lo que capturen los supervisores; nada se ha validado con datos reales; el almacén de objetos no se consulta analíticamente; el mapa lee el esquema operativo y no las vistas; y el control de acceso es ligero. La regla de detección logra precisión 0.46 y exhaustividad 0.35 y no supera a Isolation Forest al ordenar; falla sobre todo con sobreprecios. Proponen Iceberg/Parquet con DuckDB o Trino, visión por computadora sobre las fotos de avance, publicar en OWL y conforme a OC4IDS, votación cuadrática, series de tiempo para fechas de término, recalcular el criterio de costo por tipo de obra y validar en más municipios.

Comparación breve

Los tres proyectos convierten datos públicos dispersos en un almacén consultable con mapa, y el artículo de agua y el de obra pública citan explícitamente al de sismos como antecedente. Difieren en el origen de los datos (catálogos oficiales completos en sismos, una extracción parcial en agua, datos sintéticos en obra pública) y en el rigor de la evaluación: los capítulos de agua y obra pública miden latencias y evalúan su detector de anomalías contra una línea base, algo que el artículo de sismos, al ser de divulgación, no hace. Esa diferencia orienta varias de nuestras propuestas.

Referencias (APA 7.^a ed.)

- Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. *AZCATL Revista de Divulgación en Ciencias, Ingeniería e Innovación*, 4(6), 28–33. <https://doi.org/10.24275/AZC2026E1004>
- Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A., y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications and Research*. Springer.
- González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En *Advances in Computer Science Applications and Research*. Springer.